

TP2 — Embeddings y búsqueda semántica

Ayala · Cerana · Colombo · Ibarbia | Corpus: 150 sinopsis de libros de Drama

Objetivo y método

Comparamos TF-IDF, Word2Vec entrenado sobre el corpus, promedios de vectores SBW, SBERT y Doc2Vec. Los documentos combinan título y sinopsis. Para Word2Vec se eliminan puntuación, números y stopwords, conservando acentos; SBERT recibe el texto crudo. Los vectores promedio y SBERT se normalizan antes de calcular similitud coseno.

Resultados de recuperación

Modelo	Precision@3 media
TF-IDF	0.000
Word2Vec promedio	0.000
SBW promedio	0.000
SBERT	0.267
Doc2Vec	0.033
Azar (valor esperado)	0.019

La media se calcula sobre diez consultas. El piso aleatorio es el valor esperado al elegir tres libros uniformemente: cantidad de relevantes dividida por 150. SBERT logra 0,267, Doc2Vec 0,033 y el azar esperado 0,019; TF-IDF y los promedios de vectores de palabra obtienen 0,000.

SBERT y cobertura del texto

El modelo produce vectores de 512 dimensiones y limita cada entrada a 128 tokens. 141 de 150 documentos (94%) superan ese límite. La cobertura aproximada es 55.5% en promedio y 50.1% en la mediana. Esta pérdida limita la interpretación de sus resultados.


Los resultados corresponden a este corpus y estas relevancias manuales; no demuestran una ventaja general.

Distribución y proyección


Modelo	Media	Desvío	Rango
Word2Vec promedio	0.670	0.074	0.273–0.859
SBW promedio	0.901	0.051	0.502–0.968
SBERT	0.263	0.083	0.003–0.582

Se usaron los mismos 5.000 pares aleatorios. SBW presenta una similitud media cercana a 0,90, con muchos documentos próximos entre sí.

Similitud entre 5.000 pares aleatorios de documentos



PCA de documentos por modelo y género adicional



Modelo	PC1	PC2	Varianza total
Word2Vec promedio	7.8%	4.3%	12.1%
SBW promedio	12.1%	6.3%	18.4%
SBERT	4.4%	3.6%	8.0%

La proyección de dos componentes conserva entre 8,0 % y 18,4 % de la varianza. Es una inspección visual, no una representación fiel de las distancias originales.

Interpretación y límites

Si hubiera que priorizar un candidato para seguir evaluando, elegiríamos SBERT por su mayor Precision@3 (0,267 frente a 0,019 del azar). No lo desplegaríamos todavía: casi todos los textos exceden su límite, el conjunto tiene diez consultas y el resultado depende de un modelo preentrenado de terceros. La ejecución local evita enviar consultas a un servicio externo, aunque se depende de descargar y conservar los pesos. Doc2Vec y Word2Vec se entrenan localmente con semillas fijas, pero su Precision@3 fue baja en esta evaluación.

Caso de fallo

La consulta «conflictos familiares, culpa, sufrimiento» no comparte palabras literales con los textos de sus libros relevantes. En Precision@3, TF-IDF, Word2Vec promedio, SBW, SBERT y Doc2Vec obtuvieron 0,000; el azar esperado fue 0,020. TF-IDF no encuentra términos comunes con esos documentos relevantes, así que no tiene señal léxica para recuperarlos; puede puntuar otros libros que sí contengan los términos de consulta. Los modelos densos también fallaron; una hipótesis es la combinación de corpus pequeño, promedio que diluye términos y pérdida de texto en SBERT. Los resultados no permiten aislar una causa única.

Qué mide la métrica

Precision@3 mide qué fracción de los tres primeros resultados está marcada como relevante. No mide recuperación de todos los relevantes, posiciones posteriores al tercer resultado, satisfacción de usuarios ni generalización. Las relevancias manuales y las diez consultas condicionan la media.

Doc2Vec aprende vectores de 100 dimensiones y usa ``infer_vector`` para consultas. Dos inferencias de una consulta con semillas distintas tuvieron coseno 0.989 en el ejemplo inspeccionado; la inferencia sigue siendo estocástica y este caso no caracteriza toda su variabilidad.

Uso de asistentes de IA

Se utilizó ChatGPT como apoyo para reorganizar y revisar el notebook, implementar partes del análisis y estructurar este informe. Los resultados se obtuvieron al ejecutar el notebook; las consultas y sus relevancias se mantuvieron como evaluación manual del grupo.